

GÜMÜŞHANE ÜNİVERSİTESİ

İktisadi ve İdari Bilimler Fakültesi • Yönetim Bilişim Sistemleri Bölümü

MAKİNE ÖĞRENMESİ (K-MEANS) YÖNTEMİYLE TÜRKİYE'DE SAĞLIK PERSONELİ KAPASİTESİNİN KÜMELENMESİ VE COĞRAFİ DAĞILIM ANALİZİ

Sıla Merve Erturan

Bahar Batur

ÖZET

Bu çalışmada, Türkiye'deki 81 ilin sahip olduğu temel sağlık personeli (Uzman Hekim, Pratisyen Hekim, Hemşire ve Ebe) kapasitelerinin makine öğrenmesi algoritmalarıyla analiz edilmesi ve coğrafi dağılım dengesizliklerinin ortaya konulması amaçlanmıştır. Sağlık kaynaklarının dağılımındaki yapısal benzerlikleri ve bölgesel yoğunlaşmaları tespit etmek amacıyla Python programlama dili ve scikit-learn kütüphanesi üzerinden K-Means kümeleme algoritması çalıştırılmıştır. Analiz öncesinde veriler değişken ölçeklerinden arındırılmak üzere StandardScaler ile standartlaştırılmış, en uygun küme sayısı ise Dirsek Yöntemi (Elbow Method) ile belirlenmiştir. Elde edilen çok boyutlu model çıktıları, Temel Bileşen Analizi (PCA) kullanılarak iki boyutlu düzlemde görselleştirilmiştir. Analiz bulgularına göre Türkiye'deki iller; "Mega Kapasite (Uç Değer)", "Bölgesel Merkezler" ve "Standart Kapasiteli İller" olmak üzere üç belirgin kümede toplanmıştır. Çalışma, sağlık atamalarında ve stratejik kapasite yönetiminde veri odaklı karar destek sistemlerinin (DSS) entegrasyonunun gerekliliğini akademik bir çerçevede ortaya koymaktadır.

Anahtar Kelimeler: Yönetim Bilişim Sistemleri, K-Means Kümeleme, Veri Madenciliği, Sağlık Personeli Yönetimi, Python.

1. GİRİŞ

Günümüzde modern sağlık sistemlerinin sürdürülebilirliği ve hizmet kalitesi, yalnızca hastanelerin fiziksel ve teknolojik altyapısıyla değil, aynı zamanda nitelikli insan kaynağının coğrafi olarak ne kadar dengeli ve optimize dağıtıldığıyla doğrudan ilişkilidir. Sınırlı olan kamu kaynaklarının ve sağlık personelinin 81 ile nüfus, ihtiyaç ve kapasite doğrultusunda dağıtılması, makro düzeydeki en önemli yönetimsel problemlerden biridir. Karar vericilerin kısıtlı kaynakları doğru yönetebilmesi için geleneksel ve sezgisel yaklaşımlardan sıyrılarak veri odaklı politikalar üretmesi zorunlu hale gelmiştir.

Geleneksel atama ve kapasite planlama yöntemleri, iller arasındaki karmaşık yapısal farklılıkları ve gizli örüntüleri gözden kaçırabilmektedir. Bu noktada Yönetim Bilişim Sistemleri (YBS) ve veri madenciliği teknikleri, devasa büyüklükteki veri setleri içerisindeki anlamlı ilişkileri bularak süreç yönetimi ve planlamayı optimize etmemizi sağlar. Bu çalışmanın temel amacı, Türkiye'deki illerin güncel sağlık

personeli sayılarına göre

benzerliklerini K-Means kümeleme algoritması ile tespit etmek, dirsek yöntemi ve korelasyon ısı haritaları gibi yardımcı metotlarla analizi derinleştirerek sağlık politikaları için veri odaklı bir karar destek modeli sunmaktır.

2. LİTERATÜR TARAMASI

Büyük veri analitiği, veri madenciliği ve makine öğrenmesi tekniklerinin sağlık hizmetleri yönetimine entegrasyonu literatürde hızla ivme kazanan bir araştırma alanıdır. Han ve Kamber (2011) tarafından yapılan temel çalışmalarda, büyük ve çok boyutlu veri setlerinin homojen alt gruplara ayrılmasında K-Means algoritmasının yüksek hesaplama hızı ve uzaklık tabanlı segmentasyondaki doğruluk avantajları açıkça ortaya konulmuştur. Sağlık sektörü özelindeki kümeleme uygulamalarına bakıldığında ise hastanelerin performans analizi, kaynak tahsisi ve personel dağılımlarının optimizasyonu için benzer veri madenciliği algoritmalarının yoğun şekilde tercih edildiği görülmektedir (Koh & Tan, 2011).

Türkiye bağlamında gerçekleştirilen akademik araştırmalar incelendiğinde, sağlık altyapısının ve insan kaynağının bölgeler arası dağılımı genellikle geleneksel tanımlayıcı istatistiksel yöntemler veya ekonometrik modellerle ele alınmıştır (Yılmaz ve ark., 2020). Ancak illerin spesifik uzman hekim, pratisyen hekim, hemşire ve ebe bazlı insan kaynağı parametrelerinin makine öğrenmesi tabanlı bir kümeleme yaklaşımı ile taranması, durağan istatistiklere kıyasla çok daha esnek, dinamik ve doğrudan Karar Destek Sistemlerine (KDS) veri besleyecek nitelikte sonuçlar üretmektedir.

3. MATERYAL VE YÖNTEM

Araştırmada kullanılan veri seti; Türkiye'nin 81 iline ait Uzman Hekim, Pratisyen Hekim, Hemşire ve Ebe sayılarını içeren çok boyutlu resmi TÜİK verilerden derlenmiştir. Algoritmanın tasarımı, modelleme adımları ve görselleştirme süreçleri Google Colab bulut bilişim ortamında, Python 3 programlama dili ve veri bilimi standartları olan pandas, scikit-learn, matplotlib ile seaborn kütüphaneleri kullanılarak yürütülmüştür.

3.1. Veri Ön İşleme ve Ölçeklendirme


K-Means algoritması, veri noktaları arasındaki Öklid uzaklığını temel alarak çalışan hassas bir algoritmadır. Veri setinde yer alan özelliklerin sayısal büyüklükleri (örneğin il bazında hemşire sayılarının on binler düzeyinde, ebe veya pratisyen hekim sayılarının ise yüzler düzeyinde olması), algoritmanın büyük ölçekli değişkene fahiş bir ağırlık tanınmasına ve modelin sapmasına neden olur. Bu yapısal sorunu engellemek amacıyla, veri setindeki eksik veriler ilgili sütun ortalamaları ile (fillna(mean)) tamamlanmış ve ardından tüm veri setine StandardScaler uygulanmıştır. Standartlaştırma işlemi ile tüm özelliklerin ortalaması 0, standart sapması 1 olacak şekilde eşit varyansa getirilmiş ve modele eşit düzeyde etki etmeleri sağlanmıştır.

3.2. Dirsek Yöntemi (Elbow Method) ile Küme Sayısının Belirlenmesi

K-Means kümeleme modelinin en kritik kararlarından biri olan küme sayısı (k) parametresi

belirlenirken nesnel ve matematiksel bir yaklaşım olan Dirsek Yöntemi (Elbow Method) kullanılmıştır. Algoritma 1'den 10'a kadar farklı k değerleri için çalıştırılmış ve her bir değer için Küme İçi Kareler Toplamı (WCSS - Within-Cluster Sum of Squares) hesaplanmıştır. Küme sayısı arttıkça doğal olarak düşen WCSS değerinin, grafik üzerinde belirgin


bir kırılma (dirseklenme) yaptığı nokta incelenmiş ve varyanstaki değişimin optimize olduğu $k = 3$ noktası en ideal küme sayısı olarak seçilmiştir.



Şekil 1: Küme Sayısının Belirlenmesinde Kullanılan Dirsek Yöntemi (Elbow) Grafiği

3.3. Özellikler Arası Korelasyon Analizi

Model girdisi olan sağlık personeli türlerinin kendi aralarındaki doğrusal ilişkileri test etmek adına Pearson Korelasyon Katsayıları hesaplanmış ve bir Isı Haritası (Heatmap) üzerinde gösterilmiştir. Korelasyon analizine göre, özellikle Uzman Hekim ve Hemşire sayıları arasında 1.00'e yakın çok güçlü ve pozitif yönlü bir ilişki saptanmıştır. Bu durum, sağlık sisteminde uzmanlaşmış klinik altyapının genişlemesiyle birlikte hemşire işgücü ihtiyacının da eşzamanlı ve doğrusal olarak yükseldiğini yönetsel açıdan doğrulamaktadır.




Şekil 2: Değişkenler Arası Pearson Korelasyon Isı Haritası (Heatmap)

4. BULGULAR VE TARTIŞMA

Belirlenen $k = 3$ parametresi doğrultusunda eğitilen K-Means kümeleme modeli, Türkiye'deki 81 ili sahip oldukları sağlık personeli hacmine ve yapısına göre 3 belirgin kümede segmentlere ayırmıştır. Model çıktılarının ve her bir kümenin karakteristik özelliklerinin analizi aşağıda detaylandırılmıştır.

4.1. Küme Merkezlerinin ve Ortalama Personel Sayılarının Analizi


Oluşturulan kümelerin profil analizini yapabilmek adına, her bir kümenin kendi içerisindeki sağlık personeli ortalamaları hesaplanmıştır. Model çıktılarında yer alan ortalama değerler incelendiğinde, kümelerin Türkiye genelindeki dağılımı asimetrik bir hiyerarşiyi ortaya koymaktadır. Küme 1'de yer alan İstanbul merkez, tek başına devasa bir personel yoğunluğuna sahipken; Küme 0 bölgesel hubları, Küme 2 ise standart Anadolu kentlerini sembolize etmektedir. Bu hiyerarşik yapı, küme ortalamaları sütun grafiğinde net bir biçimde gözlemlenmektedir.



Şekil3:Merkezlerinin Personel Türlerine Göre Ortalama Dağılımı

4.2. PCA ile Boyut İndirgeme ve Kümelenme Yapısının Görselleştirilmesi

Veri setindeki 4 boyutlu (Uzman Hekim, Pratisyen Hekim, Hemşire, Ebe) yapının insan gözüyle analiz edilebilmesi amacıyla Temel Bileşen Analizi (PCA) uygulanarak veri 2 ana bileşene indirgenmiştir. Elde edilen iki boyutlu Dağılım Grafiğinde (Scatter Plot); yatay eksen olan Bileşen 1 illerin "Genel Personel Yoğunluğunu/ Kapasitesini" ifade ederken, dikey eksen olan Bileşen 2 ise illerin kendi içindeki "Personel Dağılım Çeşitliliğini ve Uzmanlık Dengelerini" temsil etmektedir.



Şekil 4: PCA Boyut İndirgeme Sonrası K-Means Küme Dağılım Grafiği (Scatter Plot)

4.3. Küme Profillerinin Yönetimsel Değerlendirmesi

Küme 1 (Mega Kapasite -İstanbul): Grafiğin en sağında, yatay eksen (Bileşen 1) diğer tüm veri noktalarından aşırı derecede pozitif yönde ayrılan tek bir il (Küme 1) yer almaktadır. İlgili küme, Türkiye'deki toplam sağlık işgücünün çok büyük bir bölümünü tek başına barındıran, istatistiksel açıdan net bir "aykırı değer" (outlier) oluşturan istanbul doğrulamaktadır.

Küme 0 (Bölgesel Merkezler / Büyükşehirler - 24 İl): Grafiğin orta kuşağında konumlanan ve dikey eksen (Bileşen 2) geniş bir varyasyon gösteren 24 ilden oluşan gruptur. Bu iller, Türkiye ortalamasının üzerinde sağlık personeline sahip, kendi hinterlandındaki çevre illere de ileri düzey sağlık hizmeti ve uzmanlık sunan, hasta göçü alan bölgesel merkezlerdir (Ankara, İzmir, Bursa, Trabzon, Samsun vb.).

Küme 2 (Standart Kapasiteli İller - 56 İl): Grafiğin sol tarafında, sıfır noktası civarında son derece sıkı ve yoğun bir şekilde kümelenen 56 ili kapsayan en kalabalık gruptur. Modelin 56 ili birbirine bu denli yakın konumlandırması, Türkiye'deki illerin ezici bir çoğunluğunun benzer seviyede ve nispeten kısıtlı standart bir sağlık personeli hacmiyle operasyonlarını yürüttüğünü objektif olarak kanıtlamaktadır.

5. SONUÇ VE ÖNERİLER

Bu çalışmada gerçekleştirilen veri madenciliği ve makine öğrenmesi analizi, Türkiye'deki sağlık personeli coğrafi dağılımının asimetrik ve belirgin bir biçimde kutuplaşmış bir makro yapı sergilediğini ortaya koymuştur

Yalnızca tek bir ilin başlı başına bir küme oluşturacak kadar sistemden kopması ve 56 ilin tabanda sıkışması, kriz ve afet yönetimi süreçlerinde sistemik riskler barındırabilir.

Yönetim Bilişim Sistemleri ve veri analitiği vizyonu doğrultusunda, Sağlık Bakanlığı ve üst düzey politika yapıcılara yönelik şu stratejik öneriler geliştirilmiştir:

1. Veri Odaklı Dinamik Atama Modeli: Personel planlama ve atama süreçlerinde geleneksel nüfus kotaları yerine, bu çalışmadaki gibi makine öğrenmesi kümeleme çıktılarından yararlanılmalı ve kapasite açığı çeken Küme 2'deki 56 il stratejik olarak önceliklendirilmelidir.

2. Bölgesel Hub Altyapısının Güçlendirilmesi: Mega kentin (Küme 1) üzerinde biriken aşırı hasta ve operasyon yükünün azaltılması ile olası büyük kriz durumlarında sistemin çökmesini engellemek adına; yatırımlar Küme 0'da yer alan 24 bölgesel merkeze kaydırılarak "bölgesel tampon güçler" oluşturulmalıdır.

3. Karar Destek Sistemleri (KDS) Entegrasyonu: Sağlık yönetimi bürokrasisinde anlık veri analitiğine izin veren makine öğrenmesi tabanlı akıllı Karar Destek Sistemleri kurularak insan kaynakları yönetimi dijitalleştirilmelidir.

KAYNAKÇA

Türkiye İstatistik Kurumu (TÜİK). (2024). Sağlık İstatistikleri Veri Seti. Erişim adresi: [TÜİK Veri Portalı](#)

Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.

Koh, H. C., & Tan, G. (2011). Data mining applications in healthcare. *Journal of Healthcare Information Management*, 19(2), 64-72.

Yılmaz, A., & Demir, B. (2020). Türkiye'de Sağlık Hizmetleri Dağılımının Eşitsizlik Analizi. *Sağlık Yönetimi Dergisi*, 12(3), 115-130.

Scikit-Learn Kütüphanesi Resmi Dokümantasyon Modülleri (2026). K-Means Clustering and Principal Component Analysis Evaluation Protocols.